

ITAM

EST-46125

Ciencia de Datos para Políticas Públicas

Primavera 2020

Profesor:	Adolfo De Unánue	Tel. Oficina:	(+52) 55 5628 4000 ext. 4052
Oficina:	Río Hondo - Pasillo de Estadística	E-mail:	unanue@itam.mx
Horas de oficina:	Jue y Vie 12:00-13:15pm	Sitio web:	github
Horario de la clase:	Lun/Mie, 10:00-11:30am	Salón:	RH B5 (Río Hondo)

1 Descripción del curso

El curso *Ciencia de Datos para Políticas Públicas* está diseñado para proveer entrenamiento y experiencia a los estudiantes en resolver problemas reales enfocados en políticas públicas y bienestar social, usando *machine learning*.

A lo largo de las clases, discusiones, lecturas y proyectos, los estudiantes aprenderán y experimentarán la construcción sistemas *end-to-end* de *machine learning*, empezando con la definición del proyecto y *scoping*, pasando por modelado, validación de campo y convertir el análisis en acción.

Durante el curso, estudiantes desarrollarán habilidades en formulación de problemas, trabajar con datos sucios, comunicar los resultados del sistema de *machine learning* con *stakeholders* no técnicos, discutirán sobre la interpretación del modelo, entenderán disparidades y *bias* algorítmico y como mitigar sus efectos, y evaluarán el impacto de los modelos puestos en producción.

Nota que **NO** hay ninguna clase acerca de métodos de *Machine Learning*. Esta clase es sobre lo que pasa *antes* y *después* de hacer el modelo. Es decir, la clase es sobre todo lo que es importante y donde pasarás la mayor parte del tiempo de practicante.

2 Requisitos del curso

Los estudiantes deberán saber python y tener conocimiento sobre *machine learning*, en particular:

- Conocimiento de Python: Funciones, Objetos,
- Github: Clonar, Commits, Resolver conflictos, trabajar en equipos, branches
- Algoritmos de Aprendizaje de Máquina: DecisionTree, Random Forest, Regresión Logística
- Ciencia de datos: Productos de datos, Pipeline, Labels, Métricas

2.1 Cursos Recomendados:

- Introducción a la Ciencia de Datos
- Aprendizaje de Máquina
- [Programación para Ciencia de Datos](#)

2.2 Cursos que complementan este curso:

- [Arquitectura de Productos de Datos](#)

3 Objetivos de aprendizaje del estudiante

Al finalizar este curso, el estudiante debería de ser capaz de:

- Plantear problemas de Ciencia de Datos en Políticas Públicas
- Entender el proceso completo de Ciencia de Datos y *Machine Learning*
- Reconocer y resolver problemas de *Resource prioritization* y *Early Warning Systems*
- Reconocer y resolver problemas usando métodos causales
- Comunicar los resultados de los modelos
- Evaluar el desempeño e impacto de los modelos de *machine learning*
- Evaluarán y propondrán soluciones para los problemas de disparidad y *bias* algorítmico.

4 Material del curso

Libros de texto Durante el curso utilizaremos lecturas recomendadas de diversas fuentes, por lo tanto no tendremos un libro de texto. Sin embargo, los estudiantes pueden encontrar interesante o útil la siguiente lista de libros:

- *Big Data and Social Science* edited by Foster, Ghani, et al.
- *Fairness and Machine Learning* by Barocas, Hardt, and Narayana
- *Weapons of Math Destruction* by O’Neil
- *Exploratory Data Analysis* by Tukey
- *Data Science for Business* by Provost and Fawcett

Documentos Los *Handouts*, lecturas y tareas se colocarán al repositorio.

Software Los programas, análisis de datos y simulaciones serán realizados en python.

Note

- Por favor, instala pyenv (sigue las [instrucciones](#)). En esta clase usaremos la versión Python 3.7. Te recomendamos crear un ambiente virtual llamado cdpp. (instrucciones [aquí](#))

Los estudiantes trabajarán en equipos en el desarrollo de un proyecto. Los estudiantes deberán de utilizar el repositorio de github que se les asigne.

5 Evaluación

Durante el semestre, los estudiantes trabajarán juntos en grupos en un proyecto de *machine learning* aplicado que ilustrará los conceptos discutidos en la clase y en sus lecturas.

Los componentes de la calificación incluyen:

Componente	Valor
Propuesta y <i>scoping</i> escrito del proyecto	10%
<i>Peer review</i> de tres propuestas de proyectos	2.5%
Plan técnico de ML para el proyecto	2.5%
Lista detallada de los <i>features</i> del proyecto	2.5%
Dos presentaciones <i>deep-dive</i> sobre el progreso del proyecto	10% c/u
<i>Draft</i> de la sección de propuesta de investigación para el reporte final del proyecto	5%
<i>Draft</i> de la sección de diseño de prueba de (<i>field trial design</i>) para el reporte final del proyecto	5%
Presentación final de los resultados orientada a <i>stakeholders</i>	15%
Reporte final del proyecto escrito y código	20%
Participación en clase durante la discusiones y los <i>deep-dives</i>	20%
Enviar semanalmente las formas de <i>check-in</i> y <i>feedback</i>	5%

Los datos usados para los proyectos del curso serán considerados **sensibles y privados**, por lo mismo, deberán de permanecer en el ambiente seguro de cómputo provisto para el curso. _Cualquier intento de descargar alguna porción de los datos del proyecto a una máquina fuera del ambiente seguro resultará en reprobar inmediatamente la clase_. Nota que usarás herramientas como clientes SQL, *jupyter notebooks*, etc. para interactuar con datos en los servidores remotos, pero no podrás guardar el *dataset* o una porción de este a cualquier disco local.

6 Proyecto Aplicado de ML

A partir de la segunda semana y por el resto del semestre, grupos de 4 o 5 estudiantes trabajarán en proyectos de *Machine Learning* aplicados en problemas reales de política pública.

Cada semana, cada grupo deberá de presentar un rápida (2 minutos) descripción de su estatus y dos grupos harán un *deep-dive* de su progreso (20 minutos), dando énfasis en cómo el tema de la semana aplica en su proyecto.

Además de ayudar a conectar las lecturas y discusiones con una aplicación, los *deep-dives* darán oportunidad de a los presentadores, de solicitar *feedback* y ayuda de sus compañeros en los problemas o retos que estén enfrentado (¡y que probablemente los demás estén experimentando también!),

Durante el semestre, los estudiantes serán responsables de varios entregables intermedios mientras desarrollan el proyecto:

Propuesta inicial Enviada de manera grupal. Debe de incluir el *scoping* del proyecto y estadística descriptiva preliminar acerca de las *entidades* del *dataset*. La propuesta debe de ser de 4-5 páginas de largo, sin incluir las figuras, tablas o referencias.

Plan técnico de ML Enviado de manera grupal. Formulación como proyecto de *machine learning* de lo descrito en la propuesta. Debe de incluir la descripción de los elementos del *pipeline* que el grupo estará construyendo

Descripción de *features* Lista con la descripción de los *features* específicos que se serán construidos para el proyecto. Esta lista también es enviada de manera grupal. La descripción debe de incluir los atributos que forman el *feature*, nivel de agregación disponible, estrategia de agregación (e.g. temporal o espacial, etc) y plan para resolver los valores faltantes.

Draft de la sección de propuesta de investigación *Draft* de la sección de propuesta de investigación (*research proposal*) que será incluida en el reporte final. Longitud, sin incluir las figuras, tablas o referencias, de 2-3 páginas.

Draft de la sección de diseño de prueba de campo *Draft* de la sección de diseño de prueba de campo (*field trial*) propuesta de investigación que será incluida en el reporte final. Longitud sugerida, sin incluir las figuras, tablas o referencias, de 2-3 páginas.

Al concluir el semestre, cada grupo dará una presentación final de 10 minutos más 3 de preguntas. Esta presentación debe de ser pensada para los tomadores de decisión de tu proyecto. Debe de incluir, un *overview* del problema y aproximación de solución, resultados, recomendaciones de política y limitaciones del trabajo desarrollado.

Acompañando la presentación final, deberá de entregarse un reporte escrito, de aproximadamente 15 páginas (sin incluir las figuras, tablas o referencias), que deberá de incluir:

- Resumen ejecutivo, máximo una página, en la que describas sucintamente el proyecto, resultados y recomendaciones.
- *Overview* del problema, su importancia, y el alcance y metas del proyecto actual.
- Descripción de la metodología y resultados del análisis. El reporte deberá de incluir una liga al código (¡bien documentado!) al repositorio de github del equipo.
- Diseño de la prueba de campo para evaluar la exactitud del modelo resultante en la práctica así como su habilidad para ayudar a la organización para alcanzar sus metas.
- Propuesta para futuras investigaciones que están más allá del alcance del proyecto actual, por ejemplo, novedosos algoritmos de *machine learning*, que puedan mejorar el proyecto, nuevas intervenciones de política pública para explorar, u otras oportunidades de investigación.
- Conclusiones, lecciones aprendidas y recomendaciones para la organización.

7 Temario detallado (Tentativo)

En general, el curso estará organizado alrededor de dos sesiones cada semana:

- Durante las sesiones del Lunes, cada grupo dará una actualización de 2 minutos de su proyecto, resaltando el progreso y dificultades, acto seguido discutiremos el tema de la semana y las lecturas.
- En las sesiones del Miércoles (empezando en la semana 4), dos grupos tendrán 30 minutos para hacer un *deep-dive* de sus proyectos y como se relaciona su avance con el tema de la semana.

Lo siguiente es un calendario semanal **preliminar**, incluyendo los temas a discutir y las lecturas asignadas para esa semana. Por favor, lee las lecturas obligatorias y prepárate para discutir las antes de la clase correspondiente. La mayoría de los temas pueden (y frecuentemente son) el foco de cursos completos. En la clase, veremos apenas lo suficiente para despertarte la curiosidad de ir a más profundidad en las áreas que te interesen (y encontrarás muchas preguntas de investigación sin respuesta). Las lecturas opcionales, pueden ser de interés para los estudiantes que deseen ir a más profundidad en ese tema y también darán contexto adicional a tu proyecto.

7.1 Semana 1 (Enero 20 - 24): Introducción y *scoping* del proyecto

NOTA: Esta semana y por única ocasión habrá las dos sesiones se darán el Sábado 25 de enero del 2020, en la sala Alan Turing en Santa Teresa de 8 a 11 am.

En la primera sesión, haremos la introducción al curso, sus metas y discutiremos las opciones de proyectos, de tal manera que puedas decidir en cuales estás interesado para trabajar por el resto del semestre.

En la segunda parte, hablaremos sobre el *scoping* del proyecto, definición del problema y el entendimiento y balance las metas de la organización. Mucho antes de iniciar el trabajo técnico, se deben de tomar la decisión sobre si el problema de política pública puede resolverse usando *machine learning*: ¿Es el problema significativo? ¿Se puede resolver mediante una aproximación técnica? ¿Es lo suficientemente importante para que los tomadores de decisión asignen recursos para implementar la solución? ¿Cómo se medirá el éxito? ¿Cómo las metas (las cuales regularmente se contraponen) de eficiencia, eficacia y equidad serán balanceadas?

Lecturas requeridas para el Sábado:

- *Data Science Project Scoping Guide* [Disponible en Línea](#)
- *Using Machine Learning to Assess the Risk of and Prevent Water Main Breaks* by Kumar, A, Rizvi, SAA, et al. KDD 2018. [Disponible en Línea](#)

Lecturas opcionales:

- *Deconstructing Statistical Questions* by Hand, D.J. J. Royal Stat Soc. A 157(3) 1994. [Disponible en Línea](#)

7.2 Semana 2 (Enero 27 - 31): Casos de estudio y Adquisición de datos

Esta semana, asignaremos los grupos para que empiecen a trabajar en los proyectos. Estudiar ejemplos reales, es una gran forma de entender las dificultades y sutilezas de aplicar *machine learning* a problemas de política pública, por lo que el Lunes discutiremos en clase dos aplicaciones recientes .

Lecturas requeridas para el Lunes:

- *Deploying Machine Learning Models for Public Policy: A Framework* by Ackermann, K, Walsh, J, et al. KDD 2018. [Disponible en Línea](#)
- *Fine-grained dengue forecasting using telephone triage services* by Rehman, NA, et al. Sci. Adv. 2016. [Disponible en Línea](#)
- *Predictive Modeling for Public Health: Preventing Childhood Lead Poisoning* by Potash, E, et al. KDD 2015. [Disponible en Línea](#)
- *What Happens When an Algorithm Cuts Your Health Care* by Lecher, C. 2018. (The Verge) [Disponible en Línea](#)

El Miércoles, empezaremos a discutir los detalles de adquirir datos, proteger la privacidad, y ligar registros entre varias fuentes de datos. Adquirir datos de la organización es un proceso que tiene varios aspectos legales y técnicos. Los investigadores deben de entender como los datos recibidos pueden o no ser usados (esto regularmente se formaliza con un *data use agreement* y las leyes vigentes) y asegurar que la privacidad de los individuos del *data set* es protegida (potencialmente a través del uso de restricciones de acceso a los datos y técnicas como la anonimización). Una vez adquiridos los datos, deben de ser transformados para ser ingestados en un sistema que facilite el análisis, ligar los registros de las varias fuentes de datos y estructurar los datos de tal manera que permitan el análisis pertinente.

Lecturas opcionales:

- *Broken Promises of Privacy* by Ohm, P. UCLA Law Review. 2009. *Introduction and Section 1*. [Disponible en Línea](#)
- *Data Matching* by Christen, P. Springer (2012). *Chapter 2: The Data Matching Process* [Disponible en Línea](#)
- *Big Data and Social Science* edited by Foster, Ghani, et al. *Chapter 4: Databases*.

7.3 Semana 3 (Febrero 10 - 14): Exploración de datos y repaso de *pipelines* de ML

Deberás trabajar esta semana en refinar el alcance de tu proyecto así como empezar a explorar los datos. También deberás de cargar los datos a una base de datos para poder usarlos en tu modelado.

El Lunes, daremos un repaso muy rápido de análisis de datos exploratorio (EDA). EDA es fundamental para entender las sutilezas de los datos y cómo se puede plantear el problema de política como un problema de *machine learning*. El proceso del EDA involucra calcular y visualizar estadística, explorar comportamientos temporales, entender cambios rápidos de las distribuciones e identificar valores faltantes y *outliers*. Típicamente esta fase involucra recibir mucha información y experiencia de los expertos de dominio, la cual te ayudará a comprender como los datos que tienes se relacionan con el proceso que los genera, así como sus idiosincrasias y limitaciones de los mismos.

Lecturas requeridas para el Lunes:

- TBD en EDAA
- *Practical Statistics for Data Scientists* by Bruce, A. and Bruce, P. O'Reilly (2017). *Chapter 1: Exploratory Data Analysis* [Disponible en Línea](#)

El Miércoles describiremos los componentes típicos de los *pipelines* de *machine learning*. Los *pipelines* pueden salirse de control rápidamente, ya que tienen varias partes móviles, así que código bien estructurado y modular, es crítico para detectar y arreglar los *bugs* del proceso. Esta sección del curso, proveerá

un *overview* del *pipeline*, sus partes y hablaremos de algunas de las mejores prácticas y *rules of thumb* para construirlas.

Lecturas requeridas para el Miércoles:

- *Architecting a Machine Learning Pipeline* by Koen, S. (Medium) [Disponible en Línea](#)

Lecturas opcionales:

- *Data Analysis, Exploratory* by Brillinger. [Disponible en Línea](#)
- *Meet Michelangelo: Uber's Machine Learning Platform* by Hermann, J and Del Balso, M. [Disponible en Línea](#)

7.4 Semana 4 (Febrero 17 - 21): Formulación analítica y la importancia del *Baseline*

El Miércoles de esta semana realizaremos el primer conjunto de presentaciones *deep-dive*. En esta semana, todos los grupos deberían de estar trabajando en su *pipeline* inicial.

- **Entregar** antes de la clase: Propuesta de proyecto, incluyendo *scoping* y estadística descriptiva.

A diferencia del *scoping* inicial, una formulación del problema de política pública de manera analítica sólo puede ocurrir luego de que hayas desarrollado un entendimiento de los datos que tienes, lo cual se traducirá a un mayor entendimiento del problema. En esta semana, deberás preguntar como tu variable objetivo está definida en los datos, qué tipo de información está disponible como predictores, y contra qué *baseline* te estás comparando. Casi nunca, el *baseline* apropiado es una "selección al azar" de elementos de la población, mas bien, el *baseline* debe de reflejar lo que pasa sin no existiera el modelo que estás construyendo: quizá una regla de negocio que el experto hace o un modelo estadístico anterior.

Lecturas requeridas para el Lunes:

- *Dissecting Racial Bias in an Algorithm Used to Manage the Health of Populations* by Obermeyer, Z., Powers, B., et al. Science. 2009. [Disponible en Línea](#)
- *Always Start with a Stupid Model, No Exceptions* by Ameisen, E. Medium. [Disponible en Línea](#)

Lecturas opcionales:

- *Create a Common-Sense Baseline First* by Ramakrishnan. Medium. [Disponible en Línea](#)
- *Data Science for Business* by Provost and Fawcett. O'Reilly. 2013. Chapter 2: Business Problems and Data Science [Disponible en Línea](#)

7.5 Semana 5 (Febrero 24 - 28): Feature Engineering e Imputación

El desarrollo del *pipeline* debe de continuar en tu proyecto, con especial énfasis en producir la versión más simple del sistema completo.

- **Entregar** antes del inicio de la clase, los *Peer reviews* de tres propuestas de proyectos

En la mayoría de los contextos del mundo real, expresar el conocimiento de dominio a través del desarrollo y creación de *features* puede mejorar dramáticamente el *performance* del modelo, ya que permitirá identificar que factores son probablemente predictivos y ayudarán al modelo a encontrar estas relaciones (lo contrario también puede ocurrir: que existan *features* que se creen predictivos, pero que no lo son).

Por otro lado, la mayoría de los *datasets* que encontrarás en la práctica estarán plagados con *outliers*, inconsistencias y valores faltantes. Saber como manejar estos problemas de manera inteligente será crítico en el éxito del proyecto.

Lecturas requeridas para el Lunes:

- *Caso de estudio por confirmar*. Disponible en Línea
- *Missing Data Conundrum* by Akinfaderin, W. Medium. [Disponible en Línea](#)

Lecturas opcionales:

- *Feature Engineering for Machine Learning* by Zhang, A. and Casari, A. O'Reilly. 2018. *Chapter 2: Fancy Tricks with Simple Numbers* [Disponible en Línea](#)
- *Missing-data imputation* by Gelman, A. [Disponible en Línea](#)

7.6 Semana 6 (Marzo 2 - 6): Elección de métrica de *performance* y Evaluación de clasificadores, Parte I

En esta semana, tu equipo debería de tener una versión muy simple del *pipeline* con resultados preliminares un modelo.

- **Entregar** antes del inicio de la clase, *Plan técnico de ML*

El *pipeline* va a generar una gran cantidad de modelos (definidos por su algoritmo, hiper-parámetros, *features*, etc), los cuales potencialmente solucionan tu pregunta inicial. ¿Cómo decides cuáles modelos son mejor que otros y como puedes tener confianza que tú decisión siga siendo válida en el futuro, una vez que el modelo ha sido puesto en producción? ¿Cómo deberás de balancear el *performance* y el *fairness* cuando tomes esa decisión? ¿Los modelos que tienen un desempeño similar, dan predicciones similares? ¿Qué debes de hacer si no? En esta semana empezaremos a resolver estas preguntas, enfocándonos en las estrategias de *cross-validation* y la elección de métricas de desempeño.

Lecturas requeridas para el Lunes:

- *Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure* by Roberts, DR, Bahn, V, et al. *Ecography* 40:2017. [Disponible en Línea](#)
- *The Secrets of Machine Learning* by Rudin, C. and Carlson, D. arXiv preprint: 1906.01998. 2019. [Disponible en Línea](#)

Lecturas opcionales:

- *Big Data and Social Science* edited by Foster, Ghani, et al. *Chapter 5: Machine Learning*.

7.7 Semana 7 (Marzo 9 - 13): Elección de métrica de *performance* y Evaluación de clasificadores, Parte II

En esta semana, el desarrollo del *pipeline* debe de continuar, ahora deberá de soportar más especificaciones de modelos y *features*.

Continuaremos con la discusión de la semana pasada, en particular, reduciendo el número de modelos a un conjunto útil y manejable que tengo un desempeño "bueno" para alguna definición de "bueno". Nos enfocaremos en los casos de problemas de *machine learning* con un fuerte componente temporal y en cómo seleccionar modelos balanceando estabilidad, *fairness* y desempeño.

Lecturas requeridas para el Lunes:

- *Evaluating and Comparing Classifiers* by Stapor, K. CORES 2017. [Disponible en Línea](#)
- *Transductive Optimization of Top k Precision* by Liu, LP, Dietterich, TG, et al. IJCAI 2016. [Disponible en Línea](#)

7.8 Semana 8 (Marzo 16 - 20): *Overfitting, Leakage, y Problemas en deployment*

No hay clases el 16 de marzo (Natalicio de Benito Juárez), por lo que no habrá *deep-dive* esta semana.

Al final de esta semana, tu grupo deberá de tener un conjunto preliminar de resultados "correctos pero chafas" que provienen de un *grid* simple y con *features* que se priorizaron en esta primera iteración. Quizá en algún momento, pienses: "¡Ok, este es un gran modelo! Lo he validado con datos *holdout*, justo como me enseñaron ¡Es momento de ponerlo en producción!"... Los modelos pueden no generalizar a datos que no han visto de varias maneras, y en esta semana, discutiremos algunas cosas que pueden salir mal al construir modelos para ser usados en el mundo real. *Overfitting* and *leakage* pueden invalidar el desempeño de tu modelo, aún en el contexto de un mundo estable, pero cambio en las políticas y técnicas de recolección de datos son retos considerables también.

Lecturas requeridas para el Miércoles:

- *Three Pitfalls to Avoid in Machine Learning* by Riley, P. Nature. 527. 2019 (Comment) [Disponible en Línea](#)
- *Leakage in Data Mining* by Kaufman, S., Rosset, S., et al. TKDD. 2011. [Disponible en Línea](#)
- *Why is Machine Learning Deployment Hard?* by Gonfalonieri, A. Medium. [Disponible en Línea](#)

Lecturas opcionales:

- *Data Science for Business* by Provost and Fawcett. O'Reilly. 2013. *Chapter 5: Overfitting and Its Avoidance* [Disponible en Línea](#)
- *Overview of Different Approaches to Deploying Machine Learning Models in Production* by Kervizic, J. KDnuggets. [Disponible en Línea](#)

7.9 Semana 9 (Marzo 23 - 27): *Model Interpretability, Parte I*

En este momento del semestre, tu grupo debe de continuar mejorando y expandiendo los resultados preliminares del modelado.

- **Entregar** antes del inicio de la clase, Lista de *features* detallada

La interpretabilidad de los modelos pueden ser entendida en dos niveles: **global** (como funciona el modelo en lo agregado) y **local** (porqué una predicción individual resultó de esa manera). Esta semana, nos enfocaremos en lo global: entender como el modelo está funcionando y qué significa comparar este desempeño a lo largo de las especificaciones del modelo.

Lecturas requeridas para el Lunes:

- *Interpretable Classification Models for Recidivism Prediction* by Zeng, J, Ustun, B, and Rudin, C. J. Royal Stat. Soc. A. 2016. [Disponible en Línea](#)

- *Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Readmission* by Caruana, R, et al. KDD 2015. [Disponible en Línea](#)

7.10 Semana 10 (Marzo 30 - Abril 3): Model Interpretability, Parte II

En esta semana, deben de enfocarse en evaluación, selección del modelo e interpretación.

Esta semana, discutiremos la otra cara de la interpretabilidad, nos enfocaremos en varias aplicaciones prácticas de explicaciones locales: con ellas, los científicos de datos pueden "*debuggear*" y mejorar los modelos, construir confianza entre los *stakeholders* (incluyendo el movimiento legal hacia el "derecho a la explicación"), ayudar a aquellos que actuarán con las predicciones del modelo entender cuando deben de ignorar al modelo y usar su propio juicio, e importantemente ayudar a aquellos actores a decidir no solo en quién intervenir, sino también sugerir que tipo de intervención aplicar.

Lecturas requeridas para el Lunes:

- *Why Should I Trust You? Explaining the Predictions of any Classifier* by Ribeiro, MT, Singh, S, and Guestrin, C. KDD 2016. [Disponible en Línea](#)
- *Model Agnostic Supervised Local Explanations* by Plumb, G, Molitor, D, and Talwalkar, AS. NIPS 2018. [Disponible en Línea](#)
- *Explainable machine-learning predictions for the prevention of hypoxaemia during surgery* by Lundberg, SM, Nair, B, et al. Nature Biomed. Eng. 2018. [Disponible en Línea](#)

Lecturas opcionales:

- *A Unified Approach to Interpreting Model Predictions* by Lundberg, SM and Lee, S. NIPS 2017. [Disponible en Línea](#)
- *Explainable AI for Trees* by Lundberg, SM, Erion, G, et al. arXiv preprint: arxiv/1905.04610. [Disponible en Línea](#)
- *Interpretable Classification Models for Recidivism Prediction* by Zeng, J, Ustun, B, and Rudin, C. J. Royal Stat. Soc. A. 2016. [Disponible en Línea](#)

7.11 Semana 11 (Abril 13 - 17): Algorithmic Bias y Fairness, Parte I

Deberás de estar finalizando tus resultados del modelado y deberás empezar a calcular el *bias* y disparidades en tus modelos.

Así como es importante asegurar que tu modelo haga las predicciones correctamente, también es importante que las predicciones se hagan de manera justa (*fair*). Pero ¿Qué entendemos por *fairness*? ¿Cómo puedes medirla y qué puedes hacer para mitigar disparidades que encuentres? ¿En qué parte del *pipeline* estás introduciendo *bias*? (**spoiler alert:** en cada uno de los pasos). Esta semana daremos una introducción al campo de *algorithmic fairness*.

Lecturas requeridas para el Lunes:

- *A Theory of Justice* by Rawls, J. 1971. Chapter 1: Justice as Fairness, pp. 1-19. [Disponible en Línea](#)
- *Racial Equity in Algorithmic Criminal Justice* by Huq, A. Duke Law Journal. 2018. [Disponible en Línea](#)

Lecturas opcionales:

- *Is Algorithmic Affirmative Action Legal?* by Bent, JR. Georgetown Law Journal. 2019. [Disponible en Línea](#)
- *Does Mitigating ML's Impact Disparity Require Treatment Disparity?* by Lipton, Z, McAuley, J, and Chouldechova, A. NIPS 2018. [Disponible en Línea](#)
- *Equality of Opportunity* by Roemer, JE and Trannoy, A. 2013. [Disponible en Línea](#)

7.12 Semana 12 (Abril 20 - 24): Algorithmic Bias y Fairness, Parte II

Continúa investigando las disparidades en tus resultados, así como cualquier otro análisis de post-modelado.

- **Entregar** antes del inicio de la clase, *Draft de la sección "propuesta de investigación" del reporte final*.

Continuaremos esta semana la discusión de *bias* and *fairness* con un repaso a las consideraciones prácticas y preguntas de investigación abiertas de este campo.

Lecturas requeridas para el Lunes:

- *Fairness Definitions Explained* by Verma, S and Rubin, J. [Disponible en Línea](#)
- *A case study of algorithm-assisted decision making in child maltreatment hotline screening decisions* by Chouldechova, A, Putnam-Hornstein, E, et al. PMLR. 2018. [Disponible en Línea](#)
- *Equality of Opportunity in Supervised Learning* by Hardt, M. and Price, E. NIPS 2016. [Disponible en Línea](#)
- *Classification with fairness constraints: A meta-algorithm with provable guarantees* by Celis, E, Huang, L, et al. FAT* 2019. [Disponible en Línea](#)

Lecturas opcionales:

- *Fairness Through Awareness* by Dwork, C, Hardt, M, et al. ITCS 2012. [Disponible en Línea](#)
- *Fairness Constraints: Mechanisms for Fair Classification* Zafar, M, Valera I, et al. PMLR 2017. [Disponible en Línea](#)
- *Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments* by Chouldechova, A. Big Data. 2017. [Disponible en Línea](#)

7.13 Semana 13 (Abril 27 - Mayo 01): Causalidad y Field Validation

Nos acercamos a la recta final, empieza a organizar los resultados de tu proyecto para colocarlos en el reporte y presentación final.

Aún con una cuidadosa planeación y cuidado de los datos, la única manera de verdaderamente entender qué tan bien funciona tu modelo es probándolo en el campo. Generalmente, no sólo estás atento a su predictividad, sino en la habilidad del modelo de ayudar a la organización a cumplir sus metas de política pública, como pueden ser mejorar los *outcomes* entre la población que sirven. Típicamente, esto requiere trabajar de cerca con los tomadores de decisión y desarrollar un *field trial* ya sea usando *randomization* o métodos no experimentales, dependiendo de las restricciones del problema en particular.

Lecturas requeridas para el Lunes:

- *The seven tools of causal inference, with reflections on machine learning* by Pearl, J. Comm ACM. 2019 [Disponible en Línea](#)
- TBD Caso de estudio con field trial (Lead paper? / Potash?) by TBD. [Disponible en Línea](#)

Lecturas opcionales:

- *Elements of Causal Inference* by Peters et al. MIT Press. Capítulos 1 y 2. [Disponible en Línea \(Open Access Link\)](#)

7.14 Semana 14 (Mayo 4 - 7): Del Análisis a la Acción, *Accountability* y Transparencia

Esta es la última semana de los *deep dives*. En tu proyecto, tú y tu equipo deberían de estar trabajando en preparar el reporte final y la presentación.

- **Entregar** antes del inicio de la clase, *Draft de la sección "diseño de prueba de campo" del reporte final*

Para el practicante de *machine learning*, desarrollar el modelo es sólo una parte de su trabajo. Ellos deben ser capaces de comunicar, qué es lo que sus modelos pueden (y muy importante) y no pueden lograr, a *stakeholders* no-técnicos. También deben de desarrollar la estrategia para la puesta en producción de los modelos de tal manera que permita el monitoreo continuo de las métricas de desempeño y equidad, garantizando la mejora continua utilizando como retroalimentación los errores del modelo. Estas consideraciones son frecuentemente ignoradas (especialmente cuando modelos de "caja negra" desarrollados por contratistas o consultores son puestos en producción en organizaciones que no tienen la capacidad para mantenerlos) son críticas para el éxito a largo plazo del proyecto.

Adicionalmente, practicantes e investigadores de *machine learning* e inteligencia artificial, tienen la responsabilidad de actuar de una manera ética y considerar el impacto social de su trabajo. Sin embargo, personas razonables pueden estar en desacuerdo con qué exactamente lo que hace que un comportamiento sea ético y la transparencia no tiene que ser necesariamente una meta en sí misma (de hecho hay ocasiones donde la transparencia no es deseable, por ejemplo, cuando actores con malas intenciones pueden aprovecharse del sistema).

Lecturas requeridas para el Lunes

- *Ethics and Data Science* by Loukides, M., Mason, H., and Patil, D.J. O'Reilly (2018).

Libro completo (No te preocupes, es un libro corto) [Disponible en Línea](#)

- *Communicating Data with Tableau* by Jones, B. O'Reilly (2014). *Chapter 1: Communicating Data* [Disponible en Línea](#)
- *Teaching Statistics: A Bag of Tricks* by Gelman, A and Nolan, D. O'Reilly (2014). *Chapter 11: Lying with Statistics* [Disponible en Línea](#)
- *Why what Cambridge Analytica did was Unacceptable - and how we can future-proof against it.* by Rayid Ghani. Medium. [Disponible en Línea](#)

Lecturas opcionales

- *Improving Data Displays* by Wainer, H. Chance. 2007 [Disponible en Línea](#)
- *Making Data Talk* National Cancer Institute. 2011 [Disponible en Línea](#)
- *The Visual Display of Quantitative Information* by Tufte, E. Graphics Press. 2001.

7.15 Semana 15 (Mayo 11 – 15): Presentaciones finales

Durante esta semana, cada grupo realizará una presentación (descrita anteriormente) de su proyecto aplicado de ML a problemas de políticas públicas.

7.16 Semana de Finales (Mayo 18 – 22): Fecha límite para Reporte final

Incorpora los resultados finales de tu proyecto así como la retroalimentación que te dieron en tu presentación final. Cada grupo deberá de entregar un reporte final del proyecto (descrito anteriormente).

8 Calendario

Date	Class	Tema
2020-01-25 Sat	1	Introducción al curso
2020-01-25 Sat	2	Project Scoping
2020-01-27 Mon	3	Casos de Estudio
2020-01-29 Wed	4	Adquisición de datos, Privacidad y Record Linkage
2020-02-03 Mon		Aniversario de la Constitución Mexicana
2020-02-10 Mon	5	Exploración de datos
2020-02-12 Wed	6	Pipeline de ML
2020-02-17 Mon	7	Formulación Analítica y la importancia del baseline
2020-02-17 Mon		<i>Propuesta del proyecto, con scoping y estadística descriptiva</i>
2020-02-19 Wed	8	Deep-dive
2020-02-24 Mon	9	Feature Engineering e Imputación
2020-02-24 Mon		<i>Peer-reviews de tres propuestas de proyectos</i>
2020-02-26 Wed	10	Deep-dive
2020-03-02 Mon	11	Escogiendo Métricas de desempeño y Evaluación de Clasificadores I
2020-03-02 Mon		<i>Plan técnico de ML</i>
2020-03-04 Wed	12	Deep-dive
2020-03-09 Mon	13	Escogiendo Métricas de desempeño y Evaluación de Clasificadores II
2020-03-11 Wed	14	Deep-dive
2020-03-16 Mon		Natalicio de Benito Juárez
2020-03-18 Wed	15	Overfitting, Leakage e Issues in Deployment
2020-03-23 Mon	16	Model Interpretability I
2020-03-25 Wed		<i>Lista detallada de features</i>
2020-03-25 Wed	17	Deep-dive
2020-03-30 Mon	18	Model Interpretability II
2020-04-01 Wed	19	Deep-dive
2020-04-06 Mon–2020-04-10 Fri		Semana Santa
2020-04-13 Mon	20	Algorithmic Bias y Fairness I
2020-04-15 Wed	21	Deep-dive
2020-04-20 Mon	22	Algorithmic Bias y Fairness II
2020-04-22 Wed		<i>Draft de la sección "propuesta de investigación"</i>
2020-04-22 Wed	23	Deep-dive
2020-04-27 Mon	24	Causalidad y <i>Field Validation</i>
2020-04-29 Wed	25	Deep-dive
2020-05-04 Mon	26	From Analysis to Action, Accountability and Transparency
2020-05-06 Wed		<i>Draft de la sección "diseño de prueba de campo"</i>
2020-05-06 Wed	27	Deep-dive
2020-05-11 Mon	28	Presentación final
2020-05-18 Mon	29	<i>Reporte¹⁵ final</i>

Importante

- Las fechas de entrega de tarea se muestran en *cursiva*. Los días de asueto o descanso obligatorio en **negritas**.
- Este calendario está sujeto a cambios

9 Políticas del curso

9.1 Política sobre Teléfonos, Laptops y otros dispositivos

Debido a que la mayoría del trabajo de este curso involucra discusiones en grupos y responder de manera consciente a los reportes de progreso de tus compañeros, los dispositivos móviles (incluyendo laptops, *smartphones*, tabletas, blackberries, palm pilots, apple newton, tamagotchi, entre otros) no están permitidos durante la clase. Si tienes alguna discapacidad u otra razón por la que necesites el uso de un dispositivo móvil, por favor comunícate con uno de los instructores o asistentes (TAs).

10 Tus responsabilidades

Asistencia Este curso está enfocado en discusión con tus compañeros de clase, por lo tanto, la asistencia a cada sesión es importante, tanto para aprender del curso y para contribuir a lo que otros van a aprender. Como tal, se espera que asistas a cada una de las sesiones y que tu participación sea un factor importante de tu calificación, tal como está detallado en este documento. Si algo llegará a pasar que requiera que faltes a una clase (enfermedad, conferencias, etc), por favor coméntalo con anticipación con el instructor o el TA.

Integridad académica No se tolerará ninguna violación a las políticas de integridad académica de la clase o de la universidad. Cualquier instancia de copiar, engañar, plagiar, u otra violación de integridad académica será reportada y resultará en reprobar inmediatamente el curso.

Fechas de entrega Cada día de retraso en algún entregable resultará en la reducción de la posible calificación máxima en medio punto. (e.g 9.5 a 9). Las formas semanales de *feedback* tienen la intención de proveer a los profesores con información a tiempo de tu entendimiento del curso y no serán aceptadas con retraso.

11 Recursos

Estudiantes con discapacidad Valoramos la inclusión y trabajamos para asegurar que todos los estudiantes tengan los recursos para poder participar completamente en nuestro curso. Por favor, acércate a la oficina de Dirección Escolar para que ellos puedan informarnos de cualquier acción que debamos tomar para proveerte de los recursos necesarios. Si sospechas que tienes una discapacidad pero que no está registrada en la oficina de Dirección Escolar, puedes contactarlos a al correo rcarpio@itam.mx o llamarlos al 5628 4000 ext 1500 en el horario de 8:00 h a 17:30 h.

Salud y Bienestar Como estudiante, es posible que experimentes con una variedad de reto que pueden interferir con tu aprendizaje, como relaciones desgastantes, ansiedad, uso de sustancias, sentirte triste, dificultad para concentrarte o falta de motivación. Estas situaciones de salud mental u otros eventos estresantes pueden disminuir tu desempeño académico y/o reducir tu habilidad para participar en las actividades diarias. El ITAM ofrece servicios para ayudarte, y los tratamientos funcionan.

Todos nos beneficiamos de tener apoyo en épocas difíciles. Existen recursos en el ITAM y una parte muy importante de cualquier experiencia universitaria es aprender a pedir ayuda. Pedir soporte temprano es en casi todas las circunstancias mejor que hacerlo tarde.

Si tú o alguien que conoces experimenta estrés académico, eventos de vida difíciles o sentimientos de ansiedad o depresión, te pedimos encarecidamente que busques ayuda. La **Dirección de Asuntos Estudiantiles** (DAE) está para ayudarte: llámalos al 55 5628 4088 o al correo asuntosstudentiles@itam.mx.

La **Línea Origen ITAM**, está disponible también, llámalos al 800 700 4826 o por WhatsApp al 55 7435 5042. Otra opción **Casa Grana** su teléfono es 55 6237 5682 y su correo electrónico es clinica@casagrana.com. Considera también comunicarte con un amigo, familiar o profesor en el que confíes para ayudarte a comunicarte con el soporte necesario.

Si tú o alguien que conoces tiene pensamientos suicidas o está en peligro de dañarse, llama inmediatamente a cualquier hora del día:

Línea Origen-ITAM: 800 700 4826

Línea de vida: 800 911 2000

Si la situación es de peligro llama a la policía: 911

Discriminación y Acoso Todos tienen el derecho de sentirse a salvo y respetados en el campus. Si tu o alguien que conoces está siendo afectado por acciones de acoso sexual, asalto, o discriminación, existen recursos para ayudar. Puedes hacer el reporte al contactar a la **Línea Origen ITAM** al 800 700 4826

Reportes confidenciales están disponibles a través de Línea Origen-ITAM así como también en la Dirección de Asuntos Estudiantiles al 55 5628 4088

En caso de emergencia, contacta a la seguridad en el campus a la extensión 08 si estás en Río Hondo o la extensión 2261 si estás en Santa Teresa. Fuera del campus marca al 911.

Atención médica general en las extensiones 1247 y 2258, en Río Hondo o Santa Teresa respectivamente.